

PRESENTACIÓN DOCENTE

ESPECIALIZACIÓN EN


Inteligencia de Datos

para la Gestión Estratégica

Fases de diseño e integridad referencial

Clase 2 • Taller T8002 • Dr. Lautaro Di Bartolo • 4 de septiembre de 2026, 18:00 a 21:00

2026



PUNTO DE PARTIDA

La clase 1 mostró el destino; hoy vamos por el método

- 1 La tabla plana tiene tres anomalías**
Modificar un teléfono obliga a tocar diecisiete filas. Pergamino no se puede cargar. Borrar Concepción borra que está en Tucumán.
- 2 Una fila no es un hogar: es una visita**
Lo delató la clave, que es el par id_hogar más fecha_visita.
- 3 Un archivo guarda valores y no guarda reglas**
El personas = -3 entra sin una queja, y los dos hogares 41 del T8001 entraron los dos.
- 4 La salida está a la vista**
Dos tablas donde antes había una, y las tres anomalías desaparecidas.

Lo que la clase 1 **no** dio es cómo se llega ahí desde cualquier tabla. Ese método es esta clase.

Hoy diseñamos la estructura; mañana la verificamos

Clase 2 — hoy

- Escribir para qué sirve la base
- Decidir a ojo qué cosas existen
- Pasar el dibujo a seis tablas
- Declarar las reglas que el DBMS hace cumplir

Clase 3 — mañana

- Nombrar formalmente lo que hoy se ve a ojo
- Tres pasos con criterio verificable
- Comprobar que se llega a las mismas seis tablas
- Decidir cuándo conviene no normalizar

El taller para en el diseño lógico. **No se escribe SQL y no se implementa ninguna base:** eso es Modelado de datos.

EL CASO

Doce columnas hablan de cuatro cosas, y hay una quinta escondida

relevamiento_plano.csv: 45 filas, 12 columnas, 37 hogares. La misma tabla de la clase 1, hoy mirada completa.

Columna	¿De qué habla?
id_hogar	del hogar
localidad	del hogar, o de la localidad
provincia	de la localidad
fecha_visita	de la visita
encuestador_legajo	de la visita, y del encuestador

Columna	¿De qué habla?
encuestador_nombre	del encuestador
encuestador_telefono	del encuestador
personas, ingreso	de la visita
cobertura_salud, satisfaccion	de la visita
servicios	del hogar... y de algo más

Hogares, localidades, encuestadores y visitas. Y una quinta escondida en servicios. Esa lista es todo el diseño conceptual de hoy, en borrador.

01

Diseñar es contestar cuatro preguntas, en orden

Casi todos empiezan por la cuarta, sin notar que contestaron las otras tres.

LAS CUATRO FASES

Cada fase contesta una pregunta distinta

Cada fase recibe el producto de la anterior. La confusión más común es saltar directo a la cuarta.

Fase	Pregunta que contesta	Qué produce	¿Hoy?
Requisitos	¿Para qué va a servir?	una lista de preguntas y de reglas	sección 2.1
Diseño conceptual	¿Qué cosas existen?	un diagrama de entidad y relación	sección 3
Diseño lógico	¿Cómo quedan las tablas?	tablas, columnas, claves y dominios	secciones 4 y 5
Diseño físico	¿Cómo se guarda?	índices, particiones, memoria asignada	se nombra

El diseño lógico es **donde este taller se detiene**. El físico lo decide quien administra la base, y depende del producto.

REQUISITOS

Un requisito es una pregunta concreta, no una intención

«Para guardar el relevamiento» no es un requisito: es una intención.

Preguntas que tiene que contestar

1. Hogares visitados en cada localidad
2. Cómo cambió personas entre la primera y la segunda visita
3. Visitas de cada encuestador, y en qué localidades
4. Proporción de hogares con cloacas, por provincia

Reglas que tiene que hacer cumplir

5. Un hogar pertenece a una sola localidad, y no la cambia
6. Una visita es de un hogar que existe, hecha por quien existe
7. No hay dos visitas al mismo hogar el mismo día
8. personas de 1 a 20; ingreso ≥ 0 , o no se sabe

La 4 pide cruzar provincia con servicios, que hoy son una columna repetida y una celda multivalor. La 7 es la clave compuesta de la clase 1. Un requisito bien escrito ya contiene una decisión de diseño.

POR QUÉ EL ORDEN NO SE SALTEA

Quien abre una planilla y escribe encabezados ya contestó las cuatro preguntas

Alguien puso **doce encabezados en una fila**. Con eso decidió que un hogar, una localidad, un encuestador y una visita son la misma cosa.

No lo decidió mal a propósito: **no llegó a notar que estaba decidiendo**.

Las tres anomalías de la clase 1 son la factura de esa decisión invisible.

Sin orden

- La estructura se decide tipeando
- La decisión no queda registrada
- El problema aparece meses después

Con orden

- Cada decisión se toma en su fase
- Queda escrita, y se puede discutir
- El problema aparece mientras se decide

El orden sirve para eso: **para que cada decisión se tome cuando se la puede discutir**.

02

Qué cosas existen, antes de que existan las tablas

El producto de esta fase es un dibujo que puede leer quien no sabe de bases.

Entidad, atributo e instancia: tres palabras y un aviso

Entidad

- **Una clase de cosa** sobre la que la base guarda datos
- Hogar, localidad, encuestador, visita y servicio

Atributo

- **Una propiedad** de una entidad
- La localidad tiene nombre y provincia

Instancia

- **Un caso concreto** de una entidad
- Ramallo es una instancia de localidad

La palabra «atributo» corrió un poco de lugar. En la clase 1 era una columna de una tabla. Acá es una propiedad de una entidad, y todavía no hay tablas.

Son la misma idea en dos fases: el atributo de hoy se vuelve una columna en la sección 4. Casi siempre uno a uno, y no siempre.

AHORA, EN EL NOTEBOOK

Contar combinaciones distintas, y ver aparecer las entidades

45 filas → ¿cuántas cosas distintas?

¿Cuántas veces hace falta escribir que Ramallo está en Buenos Aires?

- ▶ 1. Las cuatro cosas de las que habla la tabla

DE VUELTA A LA PRESENTACIÓN

45 filas anotan tres localidades y cuatro encuestadores

La pregunta operativa es una sola: ¿qué columnas se repiten siempre juntas?

Combinación	Veces
Ramallo — Buenos Aires	20
Córdoba — Córdoba	12
Concepción — Tucumán	13
Tres combinaciones distintas	en 45 filas

La receta, en tres pasos

Buscá grupos de columnas que se repitan siempre juntas

Contá las combinaciones distintas. **Muchas menos que las filas: hay una entidad**

Nombrá la entidad como la cosa que describen; sus atributos son esas columnas

Ese patrón tiene nombre formal y llega mañana: es una **dependencia funcional**. Hoy alcanza con el ojo.

¿localidad es un atributo del hogar o una entidad propia?


Preguntá	Si es sí
¿Tiene propiedades propias?	entidad
¿Puede existir sin ningún hogar?	entidad
¿Administro la lista de valores válidos?	entidad

Las dos respuestas, sobre el relevamiento

localidad: las tres dan sí. Tiene provincia, existe sin hogares, y su lista se administra.

cobertura_salud: las tres dan no. Guarda «sí» o «no», dos palabras que no se mueven. Una tabla de dos filas solo agrega trabajo.

La regla corta. Si lo único que necesitás es limitar los valores posibles, alcanza un dominio. Si además tiene datos propios o tiene que existir sola, es una entidad.



La misma columna puede ser atributo o entidad. Las tres preguntas deciden cuál.

AHORA, EN EL NOTEBOOK

Las tres preguntas, sobre localidad y sobre cobertura_salud

localidad • cobertura_salud

Las dos tienen pocos valores distintos. ¿Por qué una merece tabla y la otra no?

► 2. Atributo o entidad

DE VUELTA A LA PRESENTACIÓN

Un dominio limita valores; una entidad además tiene vida propia

Alcanza un dominio

- Solo hay que limitar qué valores entran
- No tiene ninguna propiedad propia
- No tiene sentido sin la fila que la contiene
- Ejemplo: cobertura_salud, satisfaccion

Hace falta una entidad


- Tiene datos propios que hay que guardar
- Tiene que poder existir sola
- La lista de valores válidos hay que administrarla
- Ejemplo: localidad, encuestador, servicio

Convertir todo en entidad es tan malo como no convertir nada. **Seis tablas es el resultado de decidir seis veces**, no de separar por costumbre.

La pregunta no es si hay vínculo: es cuántos de cada lado

Un hogar pertenece a **una sola** localidad.
Una localidad tiene **muchos** hogares.

Cardinalidad	En el relevamiento
uno a uno	ninguno
uno a muchos	localidad y hogar
muchos a muchos	hogar y servicio



La cardinalidad se decide por la regla del negocio, no por la muestra.

Escribirlo así de literal, en los dos sentidos, es lo que evita poner la clave foránea **del lado equivocado** en la sección siguiente.

LOS CUATRO VÍNCULOS

Escritos en los dos sentidos, quedan cuatro renglones

	Un...	...tiene	Cardinalidad
1	hogar pertenece a una localidad	una localidad tiene muchos hogares	uno a muchos
2	visita corresponde a un hogar	un hogar recibió muchas visitas	uno a muchos
3	visita la hizo un encuestador	un encuestador hizo muchas visitas	uno a muchos
4	hogar tiene muchos servicios	un servicio está en muchos hogares	muchos a muchos

Cinco entidades, cuatro vínculos. Tres son uno a muchos, y el cuarto tiene una consecuencia propia: **crea una tabla que hoy no existe.**

Y una segunda pregunta sobre cada vínculo, que llega en dos diapositivas: **¿es obligatorio?**

AHORA, EN EL NOTEBOOK

¿Cuántas visitas tiene cada hogar en estos datos?

29 de 37 hogares tienen una sola visita

¿El vínculo entre hogar y visita es uno a uno?

► 3. La cardinalidad no se lee en los datos

DE VUELTA A LA PRESENTACIÓN

La cardinalidad se decide por la regla, no por los datos que tenés

Visitas por hogar	Hogares
una sola visita	29
dos visitas	8
Total	37

Con 45 filas casi cualquier cosa parece uno a uno.

Preguntá si puede haber más, no si hay más.

Lo que la muestra sugiere no es la regla

Con 29 de 37, el vínculo **parece** uno a uno

Ocho hogares alcanzan para desmentirlo

Aunque ninguno tuviera dos, seguiría siendo uno a muchos: el operativo permite revisitar

Es la misma trampa que mañana aparece con las dependencias funcionales: **los datos descartan reglas, no las confirman.**

PARTICIPACIÓN

Cuando el vínculo es opcional, la ausencia de fila es un dato


Obligatoria u opcional

- Un hogar **tiene que** pertenecer a una localidad
- Una localidad **puede** no tener hogares todavía
- Es lo que resuelve la anomalía de Pergamino

Los diez nulos que el T8001 no pudo explicar.

cobertura_salud y satisfaccion vacías en las mismas diez filas. Si son un módulo opcional, son una entidad aparte con participación opcional.

La fila existe solo cuando la pregunta correspondía.



La ausencia de fila deja de ser un agujero y pasa a ser una respuesta.

Sin fila, no aplicaba. Con fila y valor vacío, correspondía y no contestó. El diseño recupera una distinción que el archivo había perdido.

EL DIAGRAMA


Cuatro elementos alcanzan para dibujar el diseño conceptual

La convención mínima

- Una **caja** por entidad, en singular
- Una **línea** por vínculo, llena u opcional
- La **cardinalidad** en cada extremo: 1 o N
- El atributo que **identifica**, subrayado

La notación no se evalúa.

Chen, pata de gallo, UML: todas dicen lo mismo. Un DER a mano, fotografiado, vale igual.



En un bloque de texto no se puede subrayar, así que el atributo que identifica va **primero**. Y fijate lo que **no** hay en el dibujo: ni tipos de dato, ni localidad_id.

03

Del dibujo a las tablas, con cuatro reglas

El dibujo ya tomó todas las decisiones. Acá solo se transcriben.

LAS CUATRO REGLAS

El pasaje del diagrama a las tablas es mecánico

	Qué se hace	En el relevamiento
1	Cada entidad se convierte en una tabla. Sus atributos son las columnas, y el subrayado es la clave primaria	5 tablas
2	Cada vínculo uno a muchos pone una clave foránea en el lado «muchos»	3 claves foráneas
3	Cada vínculo muchos a muchos crea una tabla nueva, con las dos claves foráneas	1 tabla más
4	Si una entidad no se identifica sola, su clave primaria incluye la clave foránea que la identifica	la clave de visita

Cinco entidades más una tabla de cruce: **seis tablas**. Y ninguna decisión nueva: todas se tomaron en la fase anterior.

Que sea mecánico es la recompensa de haber hecho bien el diseño conceptual. **Si el pasaje resulta difícil, el problema está en el diagrama.**

REGLA 2

La clave foránea va del lado que tiene uno

Una localidad tiene muchos hogares. ¿Dónde va la referencia?


Mal: una columna hogar_id en localidad.

Ramallo tiene quince hogares: quince valores en una celda. Es la celda multivalor que el T8001 pasó media clase desarmando.

Bien: una columna localidad_id en hogar.

Cada hogar tiene una localidad: en la celda va un solo valor.

hogar → localidad_id
visita → hogar_id
visita → encuestador_legajo



La referencia va donde cabe en una sola celda. Del otro lado no cabe.

La forma segura de decidirlo: preguntar del lado de la fila. «Un hogar, ¿cuántas localidades tiene?» Una. Entonces la columna va en hogar.

REGLA 3

Cuando ninguno de los dos lados puede guardar la referencia


Un hogar tiene muchos servicios, y un servicio está en muchos hogares. **La regla 2 falla en los dos sentidos.**

hogar_id	servicio_id
1	1
1	2
1	3
2	1
2	2

hogar_servicio

- 88 filas
- una por par
- clave compuesta
- las dos son foráneas

Esta es la tabla que resuelve servicios, que guardaba agua;luz;gas;cloacas en una celda.



Aparece una tabla que solo existe para conectar.

La tabla nueva puede tener **atributos propios**. Una fecha de conexión no es del hogar ni del servicio: es del par. Y si el par tiene atributos, casi siempre había una entidad escondida.

EL ESQUEMA COMPLETO

Seis tablas donde había una

localidad — 3

id

nombre

provincia

único: **el par**

encuestador — 4

legajo

nombre

telefono

hogar — 37

id

localidad_id →

visita — 45

hogar_id →

fecha

encuestador_legajo →

personas, ingreso

cobertura, satisfaccion

servicio — 4

id

nombre

hogar_servicio — 88

hogar_id →

servicio_id →

La clave primaria en **negrita**; la flecha marca la clave foránea.

	Filas	Celdas	Y sin embargo
Tabla plana	45	540	cada hecho, escrito muchas veces
Las seis tablas	181	594	cada hecho, escrito una sola vez

AHORA, EN EL NOTEBOOK

Construir las seis tablas a partir de la tabla plana

1 tabla de 540 celdas → 6 tablas de ¿cuántas?

¿El diseño normalizado ocupa más lugar o menos?

► 4. Las seis tablas

DE VUELTA A LA PRESENTACIÓN

Normalizar no es comprimir: son 594 celdas contra 540

Lo que no se gana

- El diseño ocupa **más** celdas, no menos
- Las claves foráneas cuestan lugar
- Las 88 filas de hogar_servicio también

Lo que sí se gana

- provincia pasó de 45 celdas a 3
- El teléfono del encuestador, de 45 a 4
- Ramallo en Buenos Aires: de 20 veces a **una**

Cada hecho está escrito una sola vez. Y hay una ganancia más, que es la que importa a largo plazo: **un dato que vive en un solo lugar se puede auditar.**

El teléfono de E04 está en una celda: se puede decir quién lo cargó y qué decía antes. Cuando está en diecisiete filas, no hay a qué preguntarle.

Las tres anomalías de la clase 1 vivían ahí, **en la diferencia entre veinte y uno.**

EL CRUCE

Si el cruce no devuelve la tabla original, la separación estaba mal


Separar es la mitad del trabajo. La otra mitad es **poder volver a juntar**: si no, separar rompió el dato en vez de organizarlo.

hogar.id	localidad_id	→ nombre	→ provincia
1	1	Ramallo	Buenos Aires
2	2	Córdoba	Córdoba
3	3	Concepción	Tucumán

Dos consecuencias

- Es la **prueba** de que una descomposición está bien hecha. Mañana se usa, y el trabajo final también
- Es la respuesta a «¿y cómo miro la tabla completa?». Se cruza, y eso se puede guardar con nombre: es una **vista**

Cruzando las seis tablas **se recupera la tabla plana original, fila por fila y valor por valor**. No se perdió nada: cambió dónde vive cada hecho.



Dos tablas se combinan por su columna común y reconstruyen la tabla ancha.

AHORA, EN EL NOTEBOOK

Reconstruir la tabla plana con merge, y compararla celda por celda

6 tablas → 45 filas × 12 columnas

Si separar estuvo bien hecho, ¿qué tiene que devolver el cruce?

► 5. El cruce

Los requisitos pasaron de «se puede» a «lo garantiza el diseño»

El cruce devolvió las 45 filas, idénticas celda por celda. **Con eso comprobado, conviene cobrar el trabajo:** volvamos a los ocho requisitos.

Requisito	En la tabla plana	En las seis tablas
1-3. Hogares, visitas y encuestadores	se puede, contando con cuidado	directo; el 3 con un cruce
4. Cloacas por provincia	no se puede sin desarmar la celda multivalor	directo, con dos cruces
5. Un hogar, una localidad	nada lo impide	lo garantizan la columna sola y la clave foránea; que no cambie, no
6. Visita de un hogar que existe	nada lo impide	lo garantiza la integridad referencial
7. No dos visitas el mismo día	nada lo impide	lo garantiza la clave primaria
8. Dominios de personas e ingreso	nada lo impide	lo garantiza el dominio declarado

«Nada lo impide» y «lo garantiza el diseño» son de otra naturaleza: los requisitos 5 a 8 **dejaron de depender de que alguien se acuerde.**

04

Crear la base es declarar el diseño de una forma que se hace cumplir


Hasta acá el diseño es un documento. Ahora el DBMS lo hace cumplir.

Cuatro de las reglas del día, en seis renglones

```
CREATE TABLE localidad (  
  id          INTEGER PRIMARY KEY,  
  nombre      TEXT    NOT NULL,  
  provincia   TEXT    NOT NULL,  
  UNIQUE (nombre, provincia)  
);
```

Solo hay que reconocer las piezas

- PRIMARY KEY es la clave primaria
- NOT NULL es obligatorio
- UNIQUE sobre dos columnas: el **par** no se repite
- TEXT e INTEGER son el tipo



El documento de reglas se vuelve un cerco activo: lo que no lo cumple, no entra.

Esta sintaxis no se aprende hoy y no se va a pedir nunca en este taller. Escribirla es el contenido de Modelado de datos.

INTEGRIDAD DE DOMINIO

El tipo es la primera restricción, y es gruesa

El tipo impide poner hola donde va un número. **No impide poner -3 donde van personas.**

Declaración	Qué impide	Ejemplo del relevamiento
rango	valores fuera de un intervalo	personas entre 1 y 20
lista de valores	cualquier valor fuera de la lista	satisfaccion: mala, regular o buena
valor por omisión	que la columna quede vacía por olvido	fecha de visita: la fecha de hoy

El T8001 detectó el 999999 de ingreso después, mirando un promedio inflado un 35%, y tuvo que deducir que era un centinela porque no había diccionario.

Con el dominio declarado, ese valor **no habría entrado**: la carga lo rechaza en el momento, con la persona que tiene el formulario adelante.

La diferencia no es que la base revise: es cuándo. Un archivo acepta el dato malo y el problema aparece meses después, disfrazado de resultado raro.


LAS TRES INTEGRIDADES

Tres preguntas distintas sobre la misma tabla

Integridad	Qué garantiza
de dominio	ningún valor imposible
de entidad	ninguna fila sin identidad
referencial	ninguna referencia al vacío

La fila huérfana llega por tres caminos

- Un error de tipo: hogar_id = 99 en lugar de 9
- Un borrado que se llevó la localidad y dejó los hogares
- Una carga masiva en el orden equivocado



Una tabla puede cumplir dos integridades y fallar la tercera.

Con id declarado como clave primaria de hogar, **el segundo hogar 41 del T8001 no entra**. La carga falla en el momento, con el formulario en la mano.

QUÉ PASA AL BORRAR


Tres desenlaces para el mismo borrado, y hay que elegir uno

Alguien intenta borrar Ramallo, y quince hogares la referencian.

Opción	Qué hace
Bloquear	falla mientras queden hogares
Propagar	borra la localidad y sus 15 hogares
Anular	deja los hogares sin referencia

Para el relevamiento

- localidad y hogar: **bloquear**
- hogar y hogar_servicio: **propagar** es razonable



El desenlace que no se elige es el que queda por omisión.

La opción peligrosa es propagar, y es la que más se elige por comodidad. La duda se resuelve siempre del mismo lado: bloquear.

AHORA, EN EL NOTEBOOK

Tres filas que la base rechaza, y la regla que cada una viola

hogar 41 repetido • hogar_id = 99 • personas = -3

Las tres entraron en el T8001 sin una queja. ¿Cuál regla las para ahora?

► 6. Las filas que la base rechaza

LISTA DE VERIFICACIÓN

Siete preguntas antes de dar por cerrado un diseño

El método

- ¿Escribí los requisitos **antes** del diagrama?
- ¿Cada entidad pasa las tres preguntas?
- ¿Cada cardinalidad está en los dos sentidos, y decidida por la regla?
- ¿Cada vínculo dice si es obligatorio u opcional?

El resultado

- ¿Cada clave foránea está del lado que tiene uno?
- ¿Cruzando las tablas se recupera la original?
- ¿Cada dominio está declarado, y cada borrado tiene su opción elegida?

La 6 es la única prueba de que no se perdió nada. Y en la 7: **si no elegiste, elegiste el valor por omisión sin saberlo.**

CIERRE DE LA CLASE

La fila que la base rechaza es el diseño funcionando

Un rechazo es un defecto que hasta hoy estaba adentro de los datos, **contando en los promedios, sin que nada avisara.**

Frente a un rechazo

- **Leé qué regla se violó.** El mensaje lo dice
- **Decidí quién está mal: el dato o la regla.** Las dos cosas pasan
- **Anotá la decisión.** Es lo que pedía el T8001, por la misma razón

El paso que más se saltea es el segundo: **una regla declarada también puede estar mal.** Aflojarla es legítimo, si es una decisión y no un reflejo.

Para mañana

- Las seis tablas de hoy son el punto de partida
- Se van a obtener otra vez, por un camino formal
- Y si los dos caminos no coinciden, una de las dos clases está mal

El diseño no evita los errores: los pone a la vista.

6 tablas · 3 integridades · 4 reglas de pasaje